




**TECNOLÓGICO
NACIONAL DE MÉXICO®**



**TEC. DE
JUÁREZ**
Forjando el futuro...

Tecnológico Nacional de México Campus Ciudad Juárez

**Ingeniería en Sistemas Computacionales
Inteligencia Artificial**

U1. Introducción a la Inteligencia Artificial

Investigación del análisis exploratorio de los datos

Grupo M

Nombre de los alumnos:

José Enrique Esquivel Torres 23110182

Irvin Eduardo Trujillo Lopez

Kenneth Eduardo Lara Hernandez

Carlos Daniel Perez Noriega

Nombre del docente:

Zapien Garcia Nancy Teresa

Fecha: 20/09/2026

Introducción

En esta investigación se presentan algunos conceptos importantes relacionados con la Inteligencia Artificial y el Machine Learning. Se explican de manera general los pasos del análisis exploratorio de datos, la forma en que se dividen los datos para entrenar y evaluar un modelo, así como la diferencia entre Inteligencia Artificial y Machine Learning. También se mencionan algunos modelos de Machine Learning, como la regresión lineal, polinomial y logística, con el objetivo de comprender de manera básica cómo se utilizan los datos para crear modelos capaces de encontrar patrones y realizar predicciones.

Particionamiento de datos

Cuando se trabaja con Machine Learning, normalmente se tiene un conjunto de datos que se utiliza para que el modelo pueda aprender y después comprobar qué tan bien funciona. Para esto, los datos se dividen en diferentes partes: entrenamiento, validación y prueba.

El conjunto de entrenamiento es la parte más grande de los datos y se utiliza para que el modelo aprenda. Aquí el algoritmo busca patrones y relaciones entre los datos para poder realizar predicciones. Por ejemplo, si queremos crear un modelo que prediga el precio de una casa, los datos de entrenamiento pueden contener información como el tamaño, número de habitaciones y ubicación, junto con el precio real.

El conjunto de validación se utiliza durante el desarrollo del modelo. Sirve para revisar cómo está funcionando y hacer ajustes en sus parámetros. De esta manera se puede elegir una configuración que funcione mejor sin utilizar todavía los datos que se reservaron para la prueba final.

Por último está el conjunto de prueba, que se utiliza cuando el modelo ya está terminado. Estos datos no se deben utilizar durante el entrenamiento, ya que su función es comprobar qué tan bien puede funcionar el modelo con información que no había visto anteriormente.

Una división común de los datos puede ser 70% para entrenamiento, 15% para validación y 15% para prueba, aunque estos porcentajes pueden cambiar dependiendo de la cantidad de datos y del problema que se esté trabajando.

Diferencias entre Inteligencia Artificial y Machine Learning

La inteligencia artificial (IA) y el aprendizaje automático (machine learning) son conceptos estrechamente vinculados, aunque no significan exactamente lo mismo. La IA es un campo amplio de la tecnología que busca desarrollar máquinas capaces de realizar tareas que normalmente requieren inteligencia humana. Por su parte, el aprendizaje automático es una rama de la IA que permite a los sistemas aprender a partir de datos, reconocer patrones, adaptarse a nueva información y mejorar su funcionamiento sin tener que ser programados de manera específica para cada situación.

- La inteligencia artificial y el aprendizaje automático se complementan para desarrollar sistemas capaces de aprender, adaptarse y tomar decisiones de manera inteligente.
- Actualmente, diferentes industrias, como el comercio, la salud, las finanzas y la ciberseguridad, utilizan estas tecnologías para mejorar sus procesos y obtener ventajas competitivas.
- El crecimiento de la IA también plantea nuevos desafíos relacionados con la ética y la seguridad, entre ellos el sesgo de los algoritmos, la protección de datos personales, los deepfakes y la desinformación.

La inteligencia artificial establece el objetivo general de crear sistemas capaces de razonar, tomar decisiones y resolver problemas de una manera similar a la inteligencia humana. El aprendizaje automático, en cambio, proporciona una de las principales herramientas para conseguirlo, ya que permite que los sistemas analicen grandes cantidades de información, encuentren patrones y mejoren sus resultados con base en los datos disponibles.

En conjunto, ambas tecnologías permiten desarrollar aplicaciones capaces de adaptarse a diferentes situaciones. Algunos ejemplos son los vehículos autónomos, las herramientas utilizadas en el diagnóstico médico y los asistentes virtuales.

Su funcionamiento puede resumirse de la siguiente manera:

- **Recopilación de datos:** se obtienen grandes cantidades de información, conocida como macrodatos o *big data*, que posteriormente se limpian, organizan y preparan para su análisis.
- **Procesamiento mediante aprendizaje automático:** los algoritmos analizan los datos y buscan patrones que puedan utilizarse para realizar predicciones o tomar decisiones.
- **Aprendizaje profundo:** mediante técnicas de *deep learning*, los sistemas pueden identificar relaciones y patrones complejos directamente a partir de grandes volúmenes de información.

- **Optimización de los modelos:** los científicos de datos evalúan los resultados y realizan ajustes para mejorar la precisión y el funcionamiento de los modelos.
- **Mejora continua:** este proceso se repite varias veces hasta obtener un modelo suficientemente preciso y preparado para utilizarse en situaciones reales.

La IA y el aprendizaje automático ya tienen aplicaciones prácticas en numerosos sectores. Algunos de los principales ejemplos son:

- **Comercio minorista:** estas tecnologías permiten administrar mejor los inventarios y desarrollar sistemas de recomendación que muestran productos basándose en las compras y actividades anteriores de los clientes.
- **Salud:** pueden utilizarse para analizar información médica, apoyar a los profesionales en la identificación de enfermedades y contribuir a seleccionar tratamientos adecuados para cada paciente.
- **Banca y finanzas:** los modelos de aprendizaje automático permiten analizar operaciones financieras en tiempo real y detectar comportamientos que podrían estar relacionados con fraudes.
- **Ventas y marketing:** la IA puede ayudar a optimizar campañas publicitarias, estimar ventas futuras, analizar las opiniones de los consumidores y detectar posibles clientes que podrían abandonar un servicio.
- **Ciberseguridad:** permite identificar comportamientos anormales en las redes, detectar amenazas potenciales y responder con mayor rapidez ante determinados ataques informáticos.
- **Servicio al cliente:** los chatbots y asistentes virtuales pueden responder preguntas, proporcionar atención inmediata y adaptar sus respuestas utilizando información de conversaciones anteriores.
- **Transporte:** la IA puede utilizarse para mejorar la circulación vehicular, apoyar el desarrollo de vehículos autónomos y optimizar las operaciones logísticas mediante modelos predictivos.
- **Manufactura:** estas herramientas ayudan a predecir posibles fallas en maquinaria, automatizar controles de calidad y mejorar diferentes procesos dentro de la cadena de suministro mediante el análisis de datos.

Modelos de Machine Learning

Dentro de la Inteligencia Artificial y el Machine Learning, existen dos enfoques que son el estándar, los cuales son el aprendizaje supervisado y el aprendizaje no supervisado. Lo que diferencia a estos dos es que uno utiliza datos que ya fueron previamente etiquetados para dar resultados, mientras que el otro no. Sin embargo, hay matices en estos dos enfoques y áreas clave en los que uno supera al otro, o que son más útiles dependiendo de la situación.

APRENDIZAJE SUPERVISADO

Es un enfoque de machine learning que se define por el uso de conjuntos de datos etiquetados. Estos datos se contemplan para entrenar o “supervisar” algoritmos para clasificar o predecir un resultado de forma precisa. Mediante entradas y salidas etiquetadas, el modelo puede medir su precisión y aprender con el tiempo.

El mismo aprendizaje puede ser dividido en dos tipos de problemas, los cuales son:

- **Clasificación:** Estos utilizan un algoritmo para asignar con precisión los datos que son de prueba en categorías específicas. Por ejemplo, estos pueden ser utilizados para separar correos que sean detectados como Spam y separarlos en una carpeta separada.
- **Regresión:** Emplea un algoritmo para comprender la relación entre las variables dependientes e independientes. Los modelos de regresión son usados para predecir valores numéricos basados en diferentes puntos de datos, como proyectar el ingreso que se llevó en las ventas de un negocio. El algoritmo de regresión puede ser dividido en otros tipos, como, por ejemplo:
 - **Regresión lineal:** Predice el valor de datos desconocidos mediante el uso de otro dato, pero que sí es conocido y está relacionado. Cómo determinar el tamaño de una casa por el tamaño de esta.
 - **Regresión polinomial:** Es un tipo de análisis estadístico que modela la relación entre una variable dependiente y una variable dependiente mediante una función curva o polinómica de grado n . Un ejemplo sería predecir la velocidad de un automóvil según el tiempo, cuando la velocidad aumenta y después disminuye.

APRENDIZAJE NO SUPERVISADO

Utiliza algoritmos de machine learning para analizar y agrupar conjuntos de datos no etiquetados. Estos algoritmos descubren patrones en los datos sin la necesidad de que se lleve a cabo una intervención humana. Los modelos de aprendizaje no supervisado pueden ser vistos mediante las tres tareas que estos utilizan:

- **Agrupación en clústeres:** Es una técnica de minería de datos que agrupa datos sin etiquetar en función de sus similitudes o diferencias. Los algoritmos de agrupación en clusters K-means asignan puntos de datos similares en grupos, donde el valor K representa el tamaño y la granularidad, o sea, como agrupar a clientes de una tienda según sus hábitos de compra.
- **Asociación:** Es otro tipo de método que utiliza las reglas diferentes para encontrar relaciones entre variables en ciertos conjuntos de datos. Puede ser utilizada para analizar el venta de un producto comprado por clientes que tambien compraron otro producto
- **Reducción de la dimensionalidad:** Esta es utilizada cuando el número de características (o dimensiones) en un conjunto de datos determinado es muy alto. Lo que hace es reducir el número de entradas a uno más considerable y, a la vez, preservar la integridad de los datos. Puede ser utilizada para el procesamiento de datos, como cuando los decodificadores eliminan el ruido para una mejora de la calidad en una imagen.
- **Análisis de Componentes Principales (PCA):** Es un método estadístico no supervisado que transforma un conjunto de datos con muchas variables en un número menor de otras variables nuevas llamadas componentes principales, conservando la mayor cantidad de información y variabilidad posible.

Pasos del análisis exploratorio de datos

El análisis exploratorio de datos, también conocido como **EDA (Exploratory Data Analysis)**, permite conocer y entender un conjunto de datos antes de utilizarlo en un modelo de Inteligencia Artificial o Machine Learning. Sus principales pasos son los siguientes:

1. Carga y revisión inicial de los datos

El primer paso consiste en cargar el conjunto de datos que se desea analizar. Este puede provenir de archivos CSV, Excel, bases de datos u otras fuentes.

Después se realiza una revisión general para conocer cuántos registros y columnas existen, cuáles son los nombres de las variables y qué tipo de información contiene cada una. También se pueden observar los primeros registros para comprobar que los datos se hayan cargado correctamente.

2. Identificación de los tipos de datos

Después se revisa qué tipo de dato contiene cada columna. Algunas variables pueden ser numéricas, como edad, precio o salario, mientras que otras pueden ser categóricas, como género, ciudad o tipo de producto.

También pueden existir fechas, textos o valores de verdadero y falso. Identificar correctamente cada tipo de dato es importante porque determina la forma en que se puede analizar cada variable.

3. Limpieza de los datos

En esta etapa se buscan posibles problemas dentro del conjunto de datos. Algunos de los más comunes son los valores faltantes, registros duplicados, errores de escritura o valores que no tienen sentido.

Por ejemplo, si en una columna de edad aparece el valor 300, probablemente se trata de un error. Dependiendo de cada situación, los datos incorrectos pueden eliminarse, corregirse o reemplazarse.

4. Análisis estadístico descriptivo

Una vez que los datos están más limpios, se pueden calcular medidas estadísticas que permitan conocer mejor su comportamiento.

Algunas de las medidas más utilizadas son:

- Media.
- Mediana.
- Moda.
- Valor mínimo.
- Valor máximo.
- Desviación estándar.

Estas medidas ayudan a entender cómo se distribuyen los datos y permiten encontrar diferencias importantes entre las variables.

5. Detección de valores atípicos

Los valores atípicos, también conocidos como **outliers**, son datos que se encuentran muy alejados de la mayoría.

Por ejemplo, si casi todos los salarios están entre \$10,000 y \$30,000, pero aparece uno de \$500,000, ese valor podría considerarse atípico.

No siempre significa que sea un error, por lo que primero debe revisarse antes de decidir si se elimina o se conserva.

6. Visualización de los datos

La visualización permite entender mejor la información mediante gráficas. Algunas de las más utilizadas durante el análisis exploratorio son los histogramas, gráficas de barras, diagramas de caja y gráficas de dispersión.

Estas gráficas permiten identificar tendencias, diferencias entre categorías, distribuciones y posibles comportamientos fuera de lo normal.

7. Análisis de relaciones entre variables

También es importante revisar si existe alguna relación entre las diferentes variables del conjunto de datos.

Por ejemplo, se puede analizar si el número de horas de estudio tiene relación con la calificación de un estudiante o si el precio de un producto cambia dependiendo de alguna característica.

Para variables numéricas se suele utilizar la correlación y representarla mediante una matriz o un mapa de calor.

8. Selección de variables importantes

Después de analizar los datos, se pueden identificar cuáles variables son realmente útiles para el problema que se desea resolver.

Algunas columnas pueden no aportar información importante, como identificadores, datos repetidos o variables que no tienen ninguna relación con el objetivo del proyecto.

Seleccionar correctamente las variables puede ayudar a que el modelo de Machine Learning sea más sencillo y eficiente.

9. Preparación de los datos

El último paso consiste en dejar los datos preparados para poder utilizarlos posteriormente.

Esto puede incluir convertir variables categóricas a valores numéricos, normalizar algunos datos o separar las variables que se utilizarán como entrada de la variable que se desea predecir.

Después de este proceso, el conjunto de datos queda en mejores condiciones para ser utilizado en algoritmos de Inteligencia Artificial y Machine Learning.

Referencias bibliográficas

- Google for Developers. (s. f.). *Conjuntos de datos: división del conjunto de datos original*. Machine Learning Crash Course. <https://developers.google.com/machine-learning/crash-course/overfitting/dividing-datasets?hl=es-419>
- Scikit-learn developers. (s. f.). *train_test_split*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html
- Google News Initiative. (s. f.). *¿Cómo aprende una máquina?* Google News Initiative. <https://newsinitiative.withgoogle.com/es-es/resources/trainings/introduction-to-machine-learning/how-does-a-machine-learn/>
- Heckert, N. A., & Filliben, J. J. (2003). *NIST/SEMATECH e-Handbook of statistical methods: Chapter 1, Exploratory data analysis*. National Institute of Standards and Technology. <https://doi.org/10.18434/M32189>
- IBM. (2021). *What is exploratory data analysis (EDA)?* IBM. <https://www.ibm.com/think/topics/exploratory-data-analysis>
- Microsoft. (2026). *Tutorial: Explore and visualize data with notebooks*. Microsoft Learn. <https://learn.microsoft.com/en-us/fabric/data-science/tutorial-data-science-explore-notebook>
- Delua, J. (s.f.). *IBM*. Obtenido de Aprendizaje supervisado frente a aprendizaje no supervisado: ¿cuál es la diferencia?: <https://www.ibm.com/mx-es/think/topics/supervised-vs-unsupervised-learning>