Tecnológico Nacional de México

Campus Ciudad Juárez

Ingeniería en Sistemas Computacionales

Inteligencia Artificial

U2. Representación del conocimiento razonamiento y los Aspectos Metodológicos en Inteligencia Artificial.

Investigación de Métricas de ML

Grupo M

Nombre de los alumnos:

José Enrique Esquivel Torres

Irvin Eduardo Trujillo Lopez

Kenneth Eduardo Lara Hernandez

Carlos Daniel Perez Noriega

Nombre del docente:

Zapien Garcia Nancy Teresa

Fecha: 10/10/2026

Índice

Introducción **3**
Modelos de Clasificación **4**
Matriz de confusión **4**
Presicion 5
Recall 6
Specificity 7
F1-Score 8
Modelos de regresión **9**
¿Qué es una métrica? **9**
MAE 10
MSE 10
RMSE 10
MAPE 11
R^2 11
Modelos de Clustering **12**
Silhouette score 12
Davies Building 12
Referencias bibliográficas **14**

Introducción

En esta investigación se presentan diferentes métricas utilizadas en Machine Learning para evaluar el rendimiento de los modelos y conocer qué tan buenos son sus resultados. Se explican las principales métricas de clasificación, regresión y clustering, así como su utilidad para identificar aciertos, errores y la calidad de las predicciones. El propósito es comprender de manera sencilla cómo funcionan estas medidas y por qué son importantes al momento de elegir y evaluar un modelo de Inteligencia Artificial.

Modelos de Clasificación

Un modelo de clasificación es un algoritmo de Machine Learning que tiene como objetivo asignar una observación a una o más categorías previamente establecidas. Dependiendo del problema, puede tratarse de una clasificación binaria, cuando solamente existen dos clases, o de una clasificación multiclase, cuando existen tres o más categorías.

Matriz de confusión

Antes de explicar las métricas, es necesario conocer la matriz de confusión, debido a que sus resultados sirven como base para calcularlas.

La matriz de confusión compara las clases reales de los datos con las clases que fueron predichas por el modelo. En una clasificación binaria se utilizan cuatro resultados principales:

- **TP (True Positive o Verdadero Positivo):** ocurre cuando el modelo predice un resultado positivo y realmente es positivo.
- **TN (True Negative o Verdadero Negativo):** ocurre cuando el modelo predice un resultado negativo y realmente es negativo.
- **FP (False Positive o Falso Positivo):** ocurre cuando el modelo predice un resultado positivo, pero realmente es negativo.
- **FN (False Negative o Falso Negativo):** ocurre cuando el modelo predice un resultado negativo, pero realmente es positivo.

La matriz puede representarse de la siguiente manera:

	Real Positivo	Real Negativo
Predicción Positiva	TP	TF
Predicción Negativa	FP	FN

Accuracy

Accuracy, también conocida como exactitud, representa la proporción de predicciones que el modelo clasificó correctamente respecto al total de predicciones realizadas y responde a la pregunta ***¿Qué porcentaje de todas las predicciones fueron correctas?*** .

Su fórmula es:

$$Accuracy = \frac{TP + TN}{TP+TN+FP+FN}$$

Los verdaderos positivos y verdaderos negativos representan las predicciones correctas, mientras que los falsos positivos y falsos negativos representan errores.

Por ejemplo, si un modelo realiza 100 predicciones y clasifica correctamente 90 de ellas, su Accuracy sería:

$$Accuracy = \frac{90 * 100}{100} = 0.90 \; -> \; 90\%$$

Esta métrica proporciona una idea general del rendimiento del modelo. Sin embargo, no siempre es suficiente para evaluar un clasificador. Cuando los datos están desbalanceados, es posible obtener una Accuracy alta aunque el modelo tenga un rendimiento deficiente en una de las clases. Por esta razón, es conveniente analizar otras métricas junto con Accuracy.

Presicion

Precision, o precisión, indica qué tan confiables son las predicciones positivas realizadas por el modelo. Es decir, de todos los casos que el modelo clasificó como positivos, muestra qué proporción realmente era positiva.

Su fórmula es:

$$Presicion = \frac{TP}{TP + FP}$$

Los falsos positivos tienen una importancia especial en esta métrica. Si el modelo clasifica muchos casos negativos como positivos, la Precision disminuye.

Por ejemplo, supongamos que un modelo predice que 50 alumnos aprobarán una materia. Después de comparar las predicciones con los resultados reales, se descubre que solamente 45 de esos alumnos realmente aprobaron.

Entonces:

$$Presicion = \frac{45}{45+5}$$

$$Presicion = \frac{45}{50} = 0.9 \; -> \; 90\%$$

Por lo tanto, la Precision sería del 90%.

En términos sencillos, se puede interpretar como: "De todos los casos que el modelo dijo que eran correctos, ¿cuántos realmente lo eran?".

Recall

Recall, también llamado sensibilidad o Tasa de Verdaderos Positivos (*True Positive Rate*), mide la capacidad del modelo para encontrar correctamente los casos positivos que realmente existen.

Su fórmula es:

$$Recall = \frac{TP}{TP+FN}$$

En este caso, los falsos negativos son especialmente importantes, porque representan casos positivos que el modelo no logró detectar.

Por ejemplo, supongamos que realmente 60 alumnos aprobaron una materia y el modelo logró identificar correctamente a 54 de ellos.

Entonces:

$$Recall = \frac{54}{54+6}$$

$$Recall = \frac{54}{60} = 0.90 \; -> \; 90\%$$

Por lo tanto:

$$Recall = 90\%$$

Una manera sencilla de entender esta métrica es preguntarse: "De todos los casos positivos que realmente existían, ¿cuántos logró encontrar el modelo?".

Specificity

Specificity, o especificidad, mide la capacidad del modelo para identificar correctamente los casos negativos. También se conoce como Tasa de Verdaderos Negativos (*True Negative Rate*).

Su fórmula es:

$$Specificity = \frac{TN}{TN + FP}$$

A diferencia del Recall, que se concentra en los positivos, la Specificity se concentra en los negativos.

Por ejemplo, si realmente existen 40 alumnos que no aprobaron y el modelo identifica correctamente a 36 de ellos, mientras que clasifica incorrectamente a 4 como aprobados:

$$Specificity = \frac{36}{36 + 4} = 0.90 \; -> \; 90\%$$

$$Specificity = \frac{36}{40} = 0.90 \; -> \; 90\%$$

Por lo tanto:

$$Specificity = 90\%$$

Esta métrica permite saber qué tan bien puede el modelo reconocer los casos que no pertenecen a la clase positiva.

F1-Score

El F1-Score es una métrica que combina Precision y Recall en un solo valor. Se utiliza principalmente cuando se busca un equilibrio entre ambas métricas.

Su fórmula es:

$$F1 - Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

También puede expresarse directamente utilizando los valores de la matriz de confusión:

$$F1 - Score = \frac{2TP}{2TP + FP + FN}$$

El F1-Score utiliza la media armónica de Precision y Recall. Su valor se encuentra entre 0 y 1, donde un valor cercano a 1 representa un mejor equilibrio entre ambas métricas.

Por ejemplo, si un modelo tiene:

$$Precision = 0.80 \; y \; Recall = 0.90$$

entonces:

$$F1 - Score = 2 * \frac{0.80 * 0.90}{0.80 + 0.90}$$

$$F1 - Score = 0.847$$

Por lo tanto:

$$F1 - Score = 84.7\%$$

El F1-Score es útil porque un modelo podría tener una Precision alta pero un Recall bajo, o viceversa. Al combinar ambas métricas, permite tener una visión más equilibrada del rendimiento del modelo.

Modelos de regresión

Los modelos de regresión son una clase de técnicas estadísticas para predecir el valor de una variable dependiente en una o varias variables independientes. Las variables independientes, también conocidas como predictoras o variables explicativas, son aquellas que se usan para realizar una predicción. En donde existen varios tipos de modelos de regresión, cada uno diseñado para diferentes tipos de datos y situaciones, tales como:

- **Regresión Lineal simple:** Es el tipo más básico de regresión. Se utiliza cuando hay una relación lineal entre una variable independiente y una dependiente. Tiene la siguiente fórmula:

$$y = \beta_0 + \beta_1 x + \epsilon$$

- **Regresión lineal múltiple:** Este modelo se usa cuando hay más de una variable independiente que influye en la variable dependiente. Tiene la siguiente fórmula:

$$y = \beta_0 + \beta_1 * x_1 + \beta_2 * x_2 + ... + \beta_n * x_n + \varepsilon$$

- **Regresión polinomial:** Este tipo de regresión se utiliza cuando la relación entre la variable independiente y la dependiente no es lineal. Se ajusta la curva polinomial a los datos, lo que permite capturar relaciones más complejas. Ejemplo de una regresión polinomial en segundo grado:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon$$

- **Regresión Logística:** Es una técnica estadística utilizada para predecir variables categóricas a partir de variables predictoras. A diferencia de la regresión lineal, que se utiliza para predecir valores continuos, la regresión logística se aplica cuando la variable dependiente es finita o categórica. Puede ser binaria, como si/bo o 1/0, lo que se conoce como regresión binaria, o puede tener múltiples categorías, como A, B, C o D, lo que se conoce como regresión multinomial.

¿Qué es una métrica?

Una métrica son medidas cuantitativas que nos permiten determinar que tan bien funciona el modelo para realizar las predicciones.

MAE

El error absoluto medio, es una métrica que calcula el promedio de las diferencias absolutas entre los valores predichos y los valores reales. A diferencia del MSE y el RMSE que elevan el cuadrado los errores, el MAE trata todos los errores por igual, tomando el valor absoluto de las diferencias. Es menos sensible a los valores atípicos en comparación con MSE y RMSE, ya que no eleva al cuadrado el error, lo que la convierte en una metricas más robusta en presencia de valores extremos.
Formula:

$$MAE = (1/n) * \Sigma |y_i - \hat{y}_i|$$

MSE

Es una medida de la diferencia cuadrática promedio entre los valores predichos y los valores reales. Lo que permite cuantificar la desviación de las predicciones respecto a los valores reales, penalizando con mayor severidad los errores debido a la operación de elevar al cuadrado.
Formula:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$$

RMSE

Es la raíz cuadrada del error cuadrático medio (MSE). Es otra métrica común para evaluar modelos de regresión, pero a diferencia del MSE, el RMSE devuelve el error en la misma unidad que la variable objetivo, lo que facilita su interpretación.
Es esencialmente la desviación estándar de los residuos (errores de predicción). Muestra cuán concentrados están los datos alrededor de la línea de mejor ajuste. Además, da una idea de cuán lejos están las predicciones de los valores reales, y los errores más grandes tienen un mejor impacto debido al proceso de elevación al cuadrado del MSE.
Fórmula:

$$RMSE = \sqrt{\frac{\sum_{i=1}^{N} \|y(i) - \hat{y}(i)\|^2}{N}}$$

MAPE

El error porcentual absoluto medio o MAPE mide el error porcentual medio entre los valores reales y los predichos, proporcionando una medida de precisión basada en porcentajes. MAPE es particularmente útil cuando se desea comprender el rendimiento del modelo en términos de errores relativos.

Fórmula:

MAPE = (1/n) * Σ (|y_i - ŷ_i| / y_i) * 10

R^2

El coeficiente de determinación (R^2) es una métrica que indica que tan bien las predicciones del modelo de regresión se aproximan a los valores reales. R^2 indica la proporción de la varianza de la variable dependiente que se puede predecir a partir de las variables dependientes.

Este compara la suma de los errores cuadráticos del modelo con la suma total de las diferencias cuadráticas entre los valores reales y la media de estos. Sin embargo, si R^2 es igual a 1, significa que el modelo se ajusta perfectamente a los datos; es decir, las predicciones coinciden con los valores reales. Por otro lado, si R^2 es igual a 0, entonces el modelo no explica ninguna parte de la varianza de la variable objetivo.

Fórmula:

$$R^2 = 1 - \frac{\sum_{i}^{N} (y_i - \hat{y}_i)^2}{\sum_{i}^{N} (y_i - \bar{y})^2}$$

Modelos de Clustering

Silhouette score

El Silhouette Score o coeficiente de silueta es un indicador empleado en ciencia de datos para medir la calidad de los agrupamientos generados mediante técnicas de clustering. Su objetivo es determinar si los datos se encuentran correctamente clasificados dentro de sus respectivos grupos, considerando dos factores: la similitud de cada elemento con los demás integrantes de su propio grupo y la distancia que existe entre este y el grupo más cercano.

El resultado de esta métrica se encuentra en un intervalo de -1 a +1. Los valores próximos a +1 reflejan una buena asignación, ya que los elementos presentan una mayor similitud con los integrantes de su grupo y una mayor separación respecto a los demás. Los valores cercanos a 0 indican que existe cierta superposición entre agrupaciones, lo que dificulta distinguir a qué grupo pertenece un dato. En cambio, los valores negativos sugieren que un elemento podría estar mejor ubicado en otro grupo.

Una de las principales utilidades del Silhouette Score es identificar el número de agrupaciones más conveniente para un conjunto de datos. Para ello, se realizan pruebas con diferentes cantidades de grupos, como tres, cuatro o cinco, y se calcula el promedio de la puntuación obtenida en cada caso. Generalmente, la configuración con el promedio más alto representa una mejor separación y cohesión entre los grupos, por lo que puede considerarse una alternativa adecuada para organizar los datos.

Davies Building

Davies-Bouldin es una métrica que se utiliza para evaluar la calidad de los grupos obtenidos mediante un modelo de clustering. Su propósito principal es determinar qué tan adecuados son los clusters formados a partir de los datos, considerando tanto la compactación interna de cada grupo como la separación existente entre los distintos grupos.

Esta métrica compara la dispersión de los elementos que pertenecen a un mismo cluster con la distancia que existe entre los diferentes clusters. De esta manera, permite identificar si los datos dentro de cada grupo presentan características similares y si, al mismo tiempo, existe una diferencia clara respecto a los elementos que forman parte de otros grupos.

En términos generales, un valor bajo de Davies-Bouldin representa un mejor resultado, ya que indica que los clusters tienen poca dispersión interna y se encuentran bien separados entre sí. Por el contrario, un valor alto puede indicar que algunos grupos se encuentran demasiado cercanos, presentan una gran dispersión o no están claramente diferenciados.

Davies-Bouldin es especialmente útil cuando se desea comparar diferentes configuraciones de un modelo de clustering, por ejemplo, al probar distintas cantidades de clusters. Al calcular esta métrica para cada configuración, se puede tener una referencia objetiva para determinar cuál organización de los datos genera grupos más definidos y consistentes.

Sin embargo, esta métrica no debe considerarse como el único criterio para determinar si un modelo de clustering es adecuado. También es importante analizar la naturaleza de los datos, visualizar los grupos obtenidos y utilizar otras métricas de evaluación cuando sea necesario. Aun así, Davies-Bouldin es una herramienta muy utilizada debido a que permite evaluar los resultados de manera sencilla y cuantitativa

Referencias bibliográficas

- IBM. (2024). *What is classification in machine learning?* IBM Think. https://www.ibm.com/think/topics/classification-machine-learning
- IBM. (2024). *What is a confusion matrix?* IBM Think. https://www.ibm.com/think/topics/confusion-matrix
- IBM. (2024). *What are classification models?* IBM Think. https://www.ibm.com/think/topics/classification-models
- scikit-learn developers. (2026). *Metrics and scoring: Quantifying the quality of predictions*. Scikit-learn. https://scikit-learn.org/stable/modules/model_evaluation.html
- scikit-learn developers. (2026). *f1_score*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
- Mounika, M. (22 de mayo de 2025). *Medium*. Obtenido de Métricas de evaluación de regresión: MSE, RMSE, MAE, R², R² ajustado, MAPE: https://medium.com/@mounikamuniganji/regression-evaluation-metrics-mse-rmse-mae-r%C2%B2-adjusted-r%C2%B2-mape-47aee557ab74
- Davies, D. L., & Bouldin, D. W. (1979). *A cluster separation measure*. IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1(2), 224–227. https://doi.org/10.1109/TPAMI.1979.4766909
- Olmos, J. L. (10 de marzo de 2024). *RPubs*. Obtenido de Gestión de Retención de Empleados: https://rpubs.com/jaquino61/1161054